Detección temprana de rasgos del espectro autista en niños pequeños

Documento técnico · Proyecto final de Machine Learning

Del documento técnico al prototipo inteligente

Maestría en IA Aplicada a la Educación e Investigación (UFHEC)
Autora: Francis Melissa Paredes Hernández · Noviembre 2026

1. Resumen

Este proyecto desarrolla un modelo de clasificación que, a partir de datos de tamizaje, estima la probabilidad de rasgos del espectro autista (TEA) en niños pequeños. Se comparan tres algoritmos con validación cruzada y se evalúan en un conjunto de prueba independiente. El modelo elegido, regresión logística, se integra en una aplicación web desplegada en Streamlit. El sistema es una herramienta de apoyo al tamizaje y no sustituye el diagnóstico clínico.

2. Problema y objetivo

La detección temprana de rasgos del espectro autista permite orientar a las familias hacia una evaluación profesional a tiempo. El objetivo es construir y documentar un prototipo reproducible que clasifique casos como "con rasgos" o "sin rasgos" usando las respuestas de un cuestionario de tamizaje y datos demográficos, y que pueda usarse mediante una interfaz sencilla.

3. Datos

Se usó el dataset real de tamizaje de Kaggle (Toddler Autism dataset, julio 2018):

- 1054 registros y 19 columnas, sin valores nulos ni duplicados.
- El 69.1% de los casos pertenece a la clase "con rasgos" (clases moderadamente desbalanceadas).
- Variables: ítems del cuestionario A1 a A10 y variables demográficas.

4. Metodología

- Ingesta y ELT de los datos, con almacenamiento en base de datos SQLite (proyecto_ml.db).
- Análisis exploratorio (EDA) y reporte de Data Profiling.
- Comparación de tres modelos: regresión logística, Gradient Boosting y Random Forest, con validación cruzada.
- Evaluación final en un conjunto de prueba de 211 casos con accuracy, precisión, recall, F1 y ROC-AUC.
- Exportación del modelo (modelo_tamizaje.joblib) y despliegue en una aplicación web.

5. Resultados

Métricas en el conjunto de prueba (211 casos):

Modelo	Accuracy	Precisión	Recall	F1	ROC-AUC
Regresión logística (elegido)	1.000	1.000	1.000	1.000	1.000
Gradient Boosting	0.981	0.986	0.986	0.986	0.999
Random Forest	0.957	0.966	0.973	0.969	0.996

Hallazgos:

- Los ítems del cuestionario (A1 a A10) concentran el poder predictivo; la variable más importante fue A9.
- Con solo datos demográficos, el ROC-AUC baja a 0.570, es decir, un poder predictivo muy limitado.

6. Limitaciones y consideraciones éticas

En el dataset original la clase se deriva de la puntuación del cuestionario, por eso las métricas son casi perfectas. El modelo aprende a reproducir esa regla y no a diagnosticar. Por tanto, los resultados no deben interpretarse como capacidad clínica real. Es una herramienta de apoyo al tamizaje, no un diagnóstico; cualquier resultado debe ser valorado por profesionales de la salud. Se recomienda validar el enfoque con datos clínicos reales y etiquetas independientes del cuestionario.

7. Prototipo y despliegue

- Aplicación web en Streamlit Community Cloud con las pestañas: Simulador, Modelos y métricas, y Sobre el proyecto.
- Simulador alternativo en HTML (simulador_asd.html) y cuaderno Jupyter (proyecto_final_ml.ipynb) ejecutable en Jupyter o Google Colab.
- Repositorio: github.com/melissaparedes3-bit/ml-deteccion-tea-ninos
- Video de presentación: https://youtu.be/lRhbCFTzooQ
- Instrucciones de ejecución en el README: descargar el repositorio, descomprimir archive.zip y ejecutar el cuaderno en orden.

8. Conclusiones

Se construyó un flujo completo de Machine Learning, desde los datos hasta una aplicación desplegada y documentada. La regresión logística resultó suficiente y fácil de interpretar, y los ítems del cuestionario son los predictores dominantes. La principal lección es metodológica: unas métricas casi perfectas deben revisarse críticamente, porque aquí reflejan cómo se construyó la etiqueta y no un diagnóstico real. Como trabajo futuro, se propone usar datos con etiquetas clínicas independientes y evaluar la calibración del modelo.