Detección temprana de rasgos del espectro autista en niños pequeños

Documento técnico

Proyecto final de Machine Learning:
Del documento técnico al prototipo inteligente

Maestría en IA Aplicada a la Educación e Investigación
Universidad Federico Henríquez y Carvajal (UFHEC)

Autora: Francis Melissa Paredes Hernández
Fecha: 9 de noviembre de 2026

1. Descripción del proyecto

Este proyecto desarrolla un modelo de clasificación que, a partir de datos de tamizaje, estima la probabilidad de que un niño pequeño presente rasgos del espectro autista (TEA). El objetivo es construir un prototipo de apoyo al tamizaje temprano, con un flujo completo: ingesta de datos, análisis exploratorio, entrenamiento y comparación de modelos, evaluación, y despliegue en una aplicación web.

Aviso importante: es una herramienta de apoyo y **no sustituye un diagnóstico profesional**.

2. Dataset

Se utilizó el dataset público *Autism Screening Data for Toddlers* de Kaggle (archivo "Toddler Autism dataset July 2018"). Contiene **1054 registros y 19 columnas**, sin valores nulos ni duplicados. El **69.1%** de los casos pertenece a la clase "con rasgos". Las variables incluyen los diez ítems del cuestionario de tamizaje (A1 a A10) y datos demográficos.

El archivo original se incluye en el repositorio como `archive.zip`.

3. Metodología

- **Ingesta y limpieza (ELT):** carga del CSV, revisión de tipos, nulos y duplicados, y almacenamiento en una base de datos SQLite (`proyecto_ml.db`).
- **Análisis exploratorio (EDA):** distribución de la variable objetivo, relación de los ítems A1 a A10 y de las variables demográficas con la clase.
- **Modelado:** comparación de tres algoritmos de clasificación con validación cruzada: regresión logística, Random Forest y Gradient Boosting.
- **Evaluación:** conjunto de prueba de 211 casos, con accuracy, precisión, recall, F1 y ROC-AUC.
- **Predicciones y conclusiones:** modelo final guardado en `modelo_tamizaje.joblib` y usado en la aplicación.

4. Resultados

Los tres modelos se evaluaron en el mismo conjunto de prueba (211 casos):

Modelo	Accuracy	Precisión	Recall	F1	ROC-AUC
Regresión logística (elegido)	1.000	1.000	1.000	1.000	1.000
Gradient Boosting	0.981	0.986	0.986	0.986	0.999
Random Forest	0.957	0.966	0.973	0.969	0.996

Hallazgos:

- Los ítems del cuestionario (A1 a A10) concentran el poder predictivo; la variable más importante fue **A9**.
- Usando solo datos demográficos, el ROC-AUC baja a **0.570**, casi al nivel del azar.
- Se eligió la regresión logística por su desempeño, su simplicidad y su interpretabilidad.

5. Limitaciones

En el dataset original la clase se deriva de la puntuación del cuestionario. Por eso las métricas son casi perfectas: el modelo aprende a reproducir esa regla y **no a diagnosticar**. Los resultados no deben interpretarse como capacidad clínica. Para un uso real harían falta datos con diagnóstico independiente del cuestionario, mayor diversidad de población y validación con especialistas.

6. Prototipo y aplicación

El prototipo se despliega como aplicación web en Streamlit Community Cloud, con tres pestañas: *Simulador*, *Modelos y métricas* y *Sobre el proyecto*. También se incluye un simulador en HTML (`simulador_asd.html`).

7. Contenido del repositorio

- `archive.zip`: dataset
- `proyecto_final_ml.ipynb`: ingesta y ELT, EDA, modelo, predicciones y conclusiones
- `modelo_tamizaje.joblib`: modelo entrenado
- `proyecto_ml.db`: base de datos SQLite
- `app.py`: aplicación web
- `simulador_asd.html`: simulador en HTML
- `requirements.txt`: dependencias
- `documento_tecnico_proyecto_final_ml.pdf`: este documento
- `README.md`: descripción general

8. Enlaces

Repositorio: https://github.com/melissaparedes3-bit/ml-deteccion-tea-ninos

Aplicación desplegada: https://ml-deteccion-tea-ninos-ugei4um3sv7kqmfvppemor.streamlit.app/

Video de presentación: https://youtu.be/lRhbCFTzooQ